

EHU

T1 - Introducción al MPC

Fundamentos del Control Predictivo basado en Modelo y su uso en la industria

Grupo de Investigación de Control Inteligente (GICI)

Curso formativo - OPTIMITIVE

Control Predictivo basado en Modelo



- 1 Introducción
- 2 Estrategia MPC
- 3 Historia
- 4 Áreas de aplicación
- 5 Fundamentos del MPC
- 6 Modelos de proceso
- 7 Función Objetivo
- 8 Ley de Control MPC




Model Predictive Control (MPC)

Es un **conjunto** de estrategias de control que se basan en:

- El uso explícito de un modelo de la planta a controlar.
- El cálculo de la acción de control minimizando una función objetivo.
- El uso del **horizonte deslizante** en el proceso de minimización.




Las estrategias MPC se implementan siempre en **tiempo discreto**, definiéndose un tiempo de ciclo (*muestreo*) T en el que se ejecutan.




Por tanto se aplican los conceptos relativos al modelado y control de *sistemas de tiempo discreto*.



El *horizonte* h es la ventana de predicción que usa el MPC para computar la acción de control $\mathbf{u}^*$.



Carretera con niebla




Carretera despejada


El tamaño del horizonte está directamente relacionado con la *visibilidad* de la evolución futura del sistema a controlar.



El *horizonte deslizante* h es la ventana de predicción de tamaño constante que se *desliza* en el tiempo junto con la planta.




El MPC se basa en minimizar el **error futuro**, mientras que estrategias como el PID se basan en corregir el **error presente**.




La ley de control del PID académico:


$$u(t) = K_p \left(e(t) + \int \frac{1}{T_i} e(t) dt + T_d \frac{de(t)}{dt} \right)$$




El MPC calcula $\mathbf{u}^*$ a cada instante de muestreo basándose en la evolución predicha en el horizonte asociado a dicho instante h .




El MPC calcula $\mathbf{u}^*$ a cada instante de muestreo basándose en la evolución predicha en el horizonte asociado a dicho instante h .




El MPC calcula $\mathbf{u}^*$ a cada instante de muestreo basándose en la evolución predicha en el horizonte asociado a dicho instante h .




- La estrategia MPC se basa en el cálculo de la acción de control óptima u en un horizonte deslizando h futuro.
- El MPC requiere que la referencia sea conocida en este horizonte.




- 1 La evolución del sistema $\hat{y}(t+k)$ se predice en el horizonte usando el *modelo de la planta*.
- 2 Se *optimiza* $u(t+k)$ para que la salida predicha $\hat{y}(t+k)$ siga a la referencia $r(t+k)$ en base a una función de coste.




- 3 Se aplica solo el primer instante de la secuencia óptima $\mathbf{u}(t)$. El resto se deshecha.




- 4 Se repite el proceso para el instante $t + 1$, considerando el estado actual del sistema, y considerando un nuevo horizonte h sobre el instante actual.



- h_1, h : definen el instante inicial y final del *horizonte de predicción*. $h_1 \neq 0$ permite eliminar efectos como tiempos muertos o respuestas inversas de sistemas de fase no mínima.
- h_u : *horizonte de control* en el que se calcula la acción de control. Si en el cálculo de $\hat{y}(t+k|t)$: $k > h_u \rightarrow u(t) = u(t-1)$. Permite reducir el coste computacional del MPC.



Las diversas variantes de MPC definen de forma diferente **el modelo** de la planta y **el optimizador**, que dependerá de las **restricciones** y la **función de coste**.




A diferencia de otras estrategias de control, el Control Predictivo surgió del ámbito industrial, con el fin de dar solución a aspectos a los que los algoritmos PID tradicionales no daban solución como:

- La sintonización de los controladores (no intuitiva).
- Las restricciones físicas de los procesos.
- El control de sistemas no lineales.
- La necesidad de ajustar el **coste económico** de la producción.

Las formulaciones académicas se desarrollaron a partir de las ideas de las comerciales, pero permitieron afianzar teóricamente el MPC.



El MPC es muy usado en aplicaciones industriales de **dinámica lenta**, donde existen **restricciones operativas** y se requiere tener un control del **coste** y la **calidad**.



Número de aplicaciones de MPC en USA en 1999 (Qin and Badgwell, 2003)

Area	Aspen Technology	Honeywell Hi-Spec	Adersa ^b	Invensys	SGS ^c	Total
Refining	1200	480	280	25		1985
Petrochemicals	450	80	—	20		550
Chemicals	100	20	3	21		144
Pulp and paper	18	50	—	—		68
Air & Gas	—	10	—	—		10
Utility	—	10	—	4		14
Mining/Metallurgy	8	6	7	16		37
Food Processing	—	—	41	10		51
Polymer	17	—	—	—		17
Furnaces	—	—	42	3		45
Aerospace/Defense	—	—	13	—		13
Automotive	—	—	7	—		7
Unclassified	40	40	1045	26	450	1601
Total	1833	696	1438	125	450	4542
First App.	DMC:1985 IDCOM-M:1987 OPC:1987	PCT:1984 RMPCT:1991	IDCOM:1973 HIECON:1986	1984	1985	
Largest App.	603 × 283	225 × 85	—	31 × 12	—	



1999: Qin & Badgwell

- Encuesta a los principales proveedores de tecnología MPC.
- Más de **4 600 aplicaciones industriales** reportadas.
- Implantación principalmente en:
 - Refino.
 - Petroquímica.
 - Industria química.


MPC como tecnología de Advanced Process Control

2021–2024: Estado actual

- Se estiman entre **5 000–10 000 aplicaciones industriales**.
- Beneficios económicos estimados: **1-2B\$/ año**
- Tecnología consolidada en refino y petroquímica.
- Expansión hacia nuevos sectores:
 - Energía y microrredes.
 - Automoción y aeroespacial.
 - Minería y metalurgia.
 - Electrónica de potencia.
 - Robótica, etc.



Las soluciones industriales de Control Predictivo han evolucionado desde su creación añadiendo diferentes funcionalidades a sus paquetes de SW: identificación, estabilidad, robustez,...



A finales de los 70 una serie de estrategias que compartían similar filosofía fueron desarrolladas de forma independiente,

Model Algorithmic Control

- Richalet, *et al* (1978).
- Basado en respuesta impulso.
- Conceptualmente sencillo.
- Comercializado como IDCOM.

Dynamic Matrix Control

- Cutler and Ramaker (1980).
- Basado en respuesta escalón.
- Basado en LP.
- Patentado en 1982.

Estos controladores se centraban en el control de plantas, ya estables, en torno a puntos de operación, dado que no se habían desarrollado estudios de estabilidad.



Durante los años 80 se desarrolló la segunda generación de controladores predictivos,

Quadratic Dynamic Matrix Control

- Cutler, *et al* (1983).
- DMC con QP.
- Resolución cuadrática.

El mayor problema de esta segunda generación era que no definía cómo abordar las soluciones no factibles en el proceso de optimización.



A finales de los 80, se incorporaron nuevos elementos para abordar el problema de las soluciones no factibles,

IDCOM-M

- Grosdidier, *et al* (1988).
- Encargado por Shell.
- Usa 2 funciones objetivo:
 - 1 Para las salidas del proceso.
 - 2 Para las entradas del proceso, si se requiere mayor número de grados de libertad debido a soluciones no factibles.
- Cuando los cambios de Punto de Operación son grandes, se relaja el cambio, suavizando este a una curva.



SMOC

- Shell Multivariable Optimal Controller, finales de los 80.
- Incorpora el uso de la formulación en espacio de estado.

Adicionalmente al IDCOM-M y el SMOC, otros algoritmos como PCT (Profimatics) y RMPC (Honeywell) fueron creados y distribuidos.



A mediados de los 90, surgió la cuarta generación de controladores predictivos industriales, en los que destacan características como:

- Control robusto de procesos.
- Herramientas gráficas para la identificación de procesos industriales en base a los errores de predicción.
- Múltiples niveles de optimización para adaptación a diferentes objetivos de control.

Controladores comerciales como el RMPCT (Robust Model Predictive Control Technology) (HoneyWell) o el DMC+ (Aspen) pertenecen a esta generación.



En los 90, a raíz del interés de la academia por el MPC, se produjo un esfuerzo investigador importante que posibilitó avanzar en la teoría y formulación del MPC,

- Utilización de modelos SS, (Orbys y Clarke (1993) GPC en SS).
- Aplicación de los Th. de Control a las estrategias MPC.
- Análisis de la estabilidad mediante inclusión de condiciones terminales o invariantes.
- Facilitó la inclusión de términos de robustez.

Gracias a este esfuerzo, en la actualidad, el Control Predictivo es una técnica de control madura en el ámbito de los sistemas lineales.




El GPC es una de las formulaciones académicas más populares en la actualidad, existiendo también variaciones sobre las ideas propuestas.

Generalized Predictive Control

- Clarke, *et al* (1987).
- Se basa en el uso de funciones de transferencia (modelo CARIMA).
- Permite el control de sistemas de fase no mínima.




Las estrategias MPC permiten definir de forma general el problema de control en el dominio temporal discreto.



La razón del éxito del MPC: **el ahorro**

- MPC permite optimizar coste y calidad.
- Optimización de procesos multivariables.
- Mayor aprovechamiento de los actuadores (restricciones).



Ventajas

- Sintonización intuitiva
- Considera restricciones
- Control óptimo

Desventajas

- Requiere modelo de proceso
- Coste computacional elevado
- Formulación mas compleja



Fundamentos MPC




Con el fin de definir una estrategia MPC es necesario definir:

- Modelo de proceso y de ruido.
- Función objetivo.
- Ley de control MPC.




El modelo de predicción es el pilar fundamental de las estrategias MPC. Este modelo será usado para predecir la salida del sistema $\hat{y}(t+k|t)$ en un instante de muestreo t en el horizonte deslizante h para $t+k$.

- Modelo impulsional.
- Modelo escalón.
- Función de transferencia.
- Espacio de estados.
- Otros: Redes Neuronales, ...



Se basa en la obtención de la *secuencia de ponderación* h_i , $i = 0, \dots, \infty$, asociada a la **respuesta impulsional unitaria** de $G_D(z)$,



Conocida la *secuencia de ponderación* h_i es posible determinar la respuesta del sistema ante cualquier entrada $U(z)$,

$$Y(z) = G_D(z) U(z) = \left(\sum_{i=0}^{\infty} h_i z^{-i} \right) U(z) = \sum_{i=0}^{\infty} (h_i U(z) z^{-i})$$



La secuencia de ponderación que requiere el modelo impulsional se obtiene *experimentalmente*,

- Método muy empleado.
- Requiere sistemas **estables**.
- Usado en algoritmos MAC.
- No requiere de conocimiento previo de la planta.
- Permite modelar sistemas MIMO con m entradas,


$$y_j(t) = \sum_{i=1}^m \sum_{l=1}^{\infty} h_l^{ij} u^i(t-l)$$

Es posible determinar la secuencia analíticamente a partir de $G_D(z)$ a través de divisiones polinómicas.




Infinite Impulse Response (IIR)

$$y(t) = \sum_{i=0}^{\infty} h_i u(t - i)$$




Finite Impulse Response (FIR)


$$y(t) = \sum_{i=1}^{N_t} h_i u(t - i)$$




En la práctica, se utilizan modelos FIR para la representación de la dinámica, existiendo un *error de truncamiento* en función de N_t ,



En la práctica, se utilizan modelos FIR para la representación de la dinámica, existiendo un *error de truncamiento* en función de N_t ,



Se basa en la obtención de la *secuencia de ponderación* g_i , $i = 0, \dots, \infty$, asociada a la **respuesta escalón unitaria** de $G_D(z)$,




Sus características son similares a las del modelo impulsional,

- Método muy empleado.
- Requiere sistemas **estables**.
- Usado en algoritmo DMC.
- No requiere de conocimiento previo de la planta.



Relación entre la respuesta impulsional y la escalón

Un impulso se puede considerar como la resta entre dos escalones desfasados un instante de muestreo,



Con lo que es posible definir la respuesta impulso en términos de **variables incrementales**,

$$\Delta u(t) = u(t) - u(t-1) = (1 - z^{-1}) u(t)$$

y además se cumple,

$$h_i = g_i - g_{i-1}$$



El modelo escalón se define en **variables incrementales**,

$$y(t) = y_0 + \sum_{i=1}^{\infty} g_i \Delta u(t - i)$$

El valor de y_0 puede tomarse nulo (sistema lineal), y es necesario truncar la respuesta para implementarla en un controlador,

$$y(t) = \sum_{i=1}^{N_t} g_i \Delta u(t - i) = \sum_{i=1}^{N_t} g_i (u(t) - u(t - i))$$



Se basa en la utilización de funciones de transferencia en el espacio z ,

$$G_D(z) = \frac{Y(z)}{X(z)} = \frac{b_0 + b_1 z^{-1} + b_2 z^{-2} + \dots + b_m z^{-m}}{1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_n z^{-n}} \quad n \geq m$$

- Requieren un número menor de parámetros que los modelos experimentales.
- Permite trabajar con sistemas inestables.
- Permite trabajar de forma compacta.
- Menos intuitivo que los modelos experimentales.

Se requiere discretizar la planta a partir de su FT continua utilizando la transformada z (muestreo exacto) y el periodo de muestreo T adecuado.



$$\begin{aligned}\mathbf{x}(t+1) &= \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t) \\ \mathbf{y}(t) &= \mathbf{C}\mathbf{x}(t)\end{aligned}$$

Donde $\mathbf{A}$ y $\mathbf{B}$ dependen de T y se obtienen discretizando el modelo SS continuo,


$$\mathbf{A}(t) = e^{\mathbf{A}_c T} \quad \mathbf{B}(t) = \left(\int_0^T e^{\mathbf{A}_c \lambda} d\lambda \right) \mathbf{B}_c$$

- Permite trabajar con sistemas MIMO.
- Permite trabajar de forma compacta.
- Si $\mathbf{x}(t)$ no es medible, se requiere de observadores.



Los modelos de predicción usados en MPC requieren el uso de un modelo de ruido o perturbación. Este modela las diferencias entre el modelo y la realidad debidas a errores de medida o de modelado.

$$n(t) = f(y(t) - \hat{y}(t))$$



La inclusión del término de ruido introduce una realimentación en el modelo de predicción $\hat{y}(t + k|t)$.




En algunas ocasiones las perturbaciones debidas a cambios aleatorios se modelan en función de su media:

Ruido Blanco

Sigue una distribución uniforme de media 0.


$$\sum_{t=0}^{\infty} n(t) = 0$$



Ruido Coloreado

Presenta un comportamiento con media no nula.

$$\sum_{t=0}^{\infty} n(t) = c$$



El modelo de perturbación ha de ser usado para calcular la salida predicha $\hat{y}(t+k|t)$ en el horizonte h . Cuando las perturbaciones no son medibles, su comportamiento se predice usando diferentes técnicas:

- Modelo de error de perturbación constante en h :
$$\hat{n}(t+k) = n(t) = y(t) - \hat{y}(t)$$
- Modelo Controlled-Auto-Regressive and Integrated Moving Average (CARIMA): $n(t) = (y(t) - \hat{y}(t))/(1 - z^{-1})$
- Otros modelos polinómicos.

Cada estrategia de MPC determina, además del modelo de planta, el modelo de ruido que utiliza.




Dado un tipo de modelo y desarrollando $\hat{y}(t + k|t)$ a lo largo del horizonte h es posible definir el **modelo de predicción vectorial**,

$$\hat{\mathbf{y}} = \mathbf{G} \mathbf{u}^+ + \mathbf{f}$$

donde,

- $\mathbf{G} \mathbf{u}^+$ es la *respuesta forzada*, dependiente de $\mathbf{u}^+$.
- $\mathbf{f}$ es la *respuesta libre*, dependiente de valores pasados $\mathbf{u}^-$ y el estado o salida actual.



Aunque cada estrategia MPC define su propia función de coste, existen dos términos que suelen incorporar:

- Error futuro de seguimiento.
- Esfuerzo de control.

La forma general habitual se corresponde con una función de coste cuadrática,

$$J(h_1, h, h_u) = \sum_{k=h_1}^h r_k (\hat{y}(t+k|t) - w(t+k))^2 + \sum_{k=1}^{h_u} q_k (u(t+k-1))^2$$

Existen formulaciones en las que se penaliza la variación de la acción de control, $\Delta u(t+k-1)$.



Las funciones de coste cuadráticas pueden escribirse en forma vectorial,

$$J = (\hat{\mathbf{y}} - \mathbf{w})^T \mathbf{R} (\hat{\mathbf{y}} - \mathbf{w}) + \mathbf{u}^+{}^T \mathbf{Q} \mathbf{u}^+$$

- Matrices de ponderación $\mathbf{R} = [r_k]$, y $\mathbf{Q} = [q_k]$ usadas para sintonizar el controlador.
- Referencia conocida $\mathbf{w}$.



Si sustituimos el modelo de predicción $\hat{\mathbf{y}} = \mathbf{G} \mathbf{u}^+ + \mathbf{f}$ en la función de coste

$$\begin{aligned} J &= (\mathbf{G} \mathbf{u}^+ + (\mathbf{f} - \mathbf{w}))^T \mathbf{R} (\mathbf{G} \mathbf{u}^+ + (\mathbf{f} - \mathbf{w})) + \mathbf{u}^{+T} \mathbf{Q} \mathbf{u}^+ \\ &= \mathbf{u}^{+T} (\mathbf{G}^T \mathbf{R} \mathbf{G} + \mathbf{Q}) \mathbf{u}^+ + 2 \mathbf{G}^T \mathbf{R} (\mathbf{f} - \mathbf{w}) \mathbf{u}^+ \\ &\quad + (\mathbf{f} - \mathbf{w})^T \mathbf{R} (\mathbf{f} - \mathbf{w}) \end{aligned}$$

dado que $(\mathbf{f} - \mathbf{w})^T \mathbf{R} (\mathbf{f} - \mathbf{w})$ es constante y no afecta a la minimización, esta función de coste toma la forma cuadrática

$$J = \frac{1}{2} \mathbf{u}^{+T} \mathbf{H} \mathbf{u}^+ + \mathbf{f}_h^T \mathbf{u}^+$$

$$\begin{aligned} \mathbf{H} &= \mathbf{G}^T \mathbf{R} \mathbf{G} + \mathbf{Q} \\ \mathbf{f}_h &= [\mathbf{G}^T \mathbf{R} (\mathbf{f} - \mathbf{w})]^T \end{aligned}$$

que es compatible con los algoritmos de optimización QP.



Los **coeficientes de ponderación** r_k y q_k definen los pesos relativos con los que se realizará la optimización de la función de coste J .

Estos coeficientes permiten una *sintonización intuitiva*:

- Un valor de 0 eliminará el factor asociado en la minimización.
- Si $r_k > q_k$, **tiene mayor relevancia** r_k **frente a** q_k , el controlador presentará menor error y un control más agresivo.
- Si $r_k < q_k$, **tiene mayor relevancia** q_k **frente a** r_k , el controlador presentará mas error y un control más moderado.

Es posible ponderar un término de forma diferente a lo largo de h ,


$$r_k(t + i) = \alpha^{h-i}$$



La referencia de minimización $w(t+k)$ es una referencia utilizada en el proceso de minimización. Suele estar suavizada para converger en el horizonte con la referencia real $r(t)$.

Suavizado por filtro de Primer Orden

$$w(t+k) = \alpha w(t+k-1) + (1-\alpha)r(t+k), \quad k = 1, \dots, h$$



La incorporación de restricciones al problema de minimización añade complejidad y evita que este tenga solución analítica.


Restricciones habituales:

- Restricciones de salida: $\underline{y} \leq y(t+k) \leq \bar{y}$
- Restricciones de la acción de control: $\underline{u} \leq u(t+k) \leq \bar{u}$
- Restricciones de la variación en la acción de control: $\underline{\Delta u} \leq \Delta u(t+k) \leq \bar{\Delta u}$

Con el fin de garantizar la estabilidad o la robustez, se suelen incorporar términos adicionales de restricción. Las restricciones *duras* no son recomendables.



La obtención de $u(t)$ requiere resolver un problema de minimización,



En presencia de restricciones la solución analítica del problema de minimización no existe.



Dada una función de coste J ,

$$J = \frac{1}{2} \mathbf{u}^{+T} \mathbf{H} \mathbf{u}^+ + \mathbf{f}_h \mathbf{u}^+$$

La secuencia óptima de control u^+ se obtiene minimizando el siguiente problema,

$$V = \min_u J(u^+, y(t))$$

s.a.

$$\underline{y} \leq y(t+k) \leq \bar{y}$$

$$\underline{u} \leq u(t+k) \leq \bar{u}$$

$$\underline{\Delta u} \leq \Delta u(t+k) \leq \overline{\Delta u}$$



- 1 Definir el modelo de proceso.
- 2 Definir $\hat{y}(t + k|t)$ para todo el horizonte en base al modelo.
- 3 Definir las matrices $\mathbf{G}$ y el vector $\mathbf{f}$ que define el modelo de predicción en el horizonte.
- 4 Definir las restricciones en función de $\mathbf{u}^+$.
- 5 Formular el problema QP.



Curso formativo – OPTIMITIVE

Fundamentos del Control Predictivo basado en Modelo

y su uso en la industria

Autoría de los materiales

Este trabajo se ha desarrollado a partir de materiales editados por

Asier Zubizarreta Pico y **Eloy Irigoyen Gordo**

y el libro de referencia *Model Predictive Control (3rd. edition)*

Grupo de Investigación en Control Inteligente (GICI)

Universidad del País Vasco / Euskal Herriko Unibertsitatea

